Metaheurísticas

Aula 6 — PSO e ACO

Raoni F. S. Teixeira · 1s/2026

Objetivos desta aula

Ao final desta aula, o aluno deve ser capaz de:

1. Derivar as equações de velocidade e posição do PSO a partir da analogia com dinâmica de enxames e identificar o papel de cada coeficiente;
2. Analisar a condição de estabilidade do PSO e selecionar coeficientes que garantam convergência;
3. Descrever o mecanismo de estigmergia do ACO, distinguir as variantes ACS e MMAS e justificar a escolha entre elas;
4. Aplicar PSO aos benchmarks contínuos da Aula 5 e comparar com AG e DE;
5. Aplicar ACO ao TSP e comparar com SA e Busca Tabu das Aulas 3–4;
6. Confrontar os quatro algoritmos populacionais do Módulo 3 (AG, DE, PSO, ACO) em termos de domínio de aplicação, custo de calibração e desempenho esperado.

1 Otimização por Enxame de Partículas (PSO)

1.1 Motivação e origem

O **PSO** (*Particle Swarm Optimization*) foi proposto por Kennedy e Eberhart em 1995, inspirado no comportamento coletivo de bandos de pássaros e cardumes de peixes. A observação central é que indivíduos em um grupo navegam coletivamente sem coordenação centralizada: cada indivíduo ajusta sua trajetória com base em sua própria experiência passada e na experiência do grupo.

Na analogia computacional, cada solução candidata é uma **partícula** que se move pelo espaço de busca com uma **velocidade** influenciada por duas forças: a atração em direção à melhor posição que a partícula já visitou (**memória cognitiva**) e a atração em direção à melhor posição já visitada por qualquer partícula do enxame (**memória social**).

1.2 Equações de movimento

Dado um enxame de N_p partículas, cada uma com posição $\boldsymbol{x}_i^t \in \mathbb{R}^n$ e velocidade $\boldsymbol{v}_i^t \in \mathbb{R}^n$ na iteração t, a atualização é:

$$\boldsymbol{v}_i^{t+1} = \omega \boldsymbol{v}_i^t + c_1 \boldsymbol{r}_1 \circ (\boldsymbol{p}_i - \boldsymbol{x}_i^t) + c_2 \boldsymbol{r}_2 \circ (\boldsymbol{g} - \boldsymbol{x}_i^t)$$

$$\boldsymbol{x}_i^{t+1} = \boldsymbol{x}_i^t + \boldsymbol{v}_i^{t+1}$$

onde $\circ$ denota multiplicação elemento a elemento e:

- ω é o **peso de inércia** — controla a influência da velocidade anterior; ω alto favorece exploração, ω baixo favorece explotação;
- c_1 é o **coeficiente cognitivo** — peso da atração pela melhor posição pessoal $\boldsymbol{p}_i$;
- c_2 é o **coeficiente social** — peso da atração pela melhor posição global $\boldsymbol{g}$;
- $\boldsymbol{r}_1, \boldsymbol{r}_2 \in [0,1]^n$ são vetores de números aleatórios independentes que introduzem estocasticidade nos movimentos.

Definição — Memória cognitiva e social

- **Melhor pessoal** $\boldsymbol{p}_i$: melhor posição visitada pela partícula i ao longo de toda a execução. Atualizada sempre que $f(\boldsymbol{x}_i^{t+1}) < f(\boldsymbol{p}_i)$.
- **Melhor global** $\boldsymbol{g}$: melhor posição visitada por qualquer partícula do enxame. $\boldsymbol{g} = \arg\min_i f(\boldsymbol{p}_i)$.

Note que $\boldsymbol{g}$ é monotonicamente não-crescente ao longo da execução: uma vez encontrado um bom ponto, ele nunca é descartado. Isso é análogo ao s^* mantido pelo SA e pela Busca Tabu.

1.3 Condição de estabilidade

A análise de Clerc & Kennedy (2002) mostra que a condição necessária e suficiente para estabilidade (convergência das posições) é:

$$\omega < 1, \quad c_1 + c_2 < 2(1+\omega)$$

Uma configuração clássica que satisfaz essas condições: $\omega = 0.729$, $c_1 = c_2 = 1.496$ (derivados do **fator de constrição** de Clerc). Esses valores são o ponto de partida recomendado para qualquer problema.

⚠️ Atenção

Sem satisfazer a condição de estabilidade, as partículas podem divergir — velocidades crescem sem limite e o enxame se dispersa sem explorar nenhuma região adequadamente. O sintoma característico é o melhor valor global **piorando** ao longo das iterações, o que nunca deveria ocorrer já que $\boldsymbol{g}$ é o melhor histórico e nunca é descartado.

1.4 Inércia variável

Uma estratégia prática é reduzir ω linearmente ao longo da execução:

$$\omega^t = \omega_{\max} - \frac{\omega_{\max} - \omega_{\min}}{T_{\max}} \cdot t$$

com $\omega_{\max} = 0.9$ e $\omega_{\min} = 0.4$. Isso concentra exploração nas iterações iniciais e refinamento nas finais — analogia direta ao esquema de resfriamento do SA, mas sem parâmetro de temperatura explícito.

1.5 Topologias de vizinhança

A definição de $\boldsymbol{g}$ depende da **topologia do enxame**: quais partículas cada partícula pode "ver".

Topologia global (gbest). Todas as partículas compartilham um único $\boldsymbol{g}$ — o melhor de todo o enxame. Convergência rápida, mas alta pressão social favorece convergência prematura em paisagens multimodais.

Topologia em anel (lbest). Cada partícula conhece apenas seus k vizinhos mais próximos no índice (tipicamente $k = 2$). O melhor local $\boldsymbol{g}_i$ é o melhor dos vizinhos de i. Convergência mais lenta, mas maior resistência a ótimos locais — a informação do ótimo se propaga gradualmente pelo enxame, permitindo que diferentes regiões sejam exploradas em paralelo.

1.6 Algoritmo completo

Algoritmo — PSO com inércia variável e gbest

```
PSO(f, N_p, T_max, omega_max, omega_min, c1, c2, x_min, x_max):
  para i = 1 até N_p:
    x_i ← uniforme(x_min, x_max)
    v_i ← uniforme(-(x_max - x_min), x_max - x_min)
    p_i ← x_i
  g ← argmin_i f(p_i)

  para t = 1 até T_max:
    omega ← omega_max - (omega_max - omega_min) * t / T_max

    para i = 1 até N_p:
      r1 ← uniforme(0,1)^n
      r2 ← uniforme(0,1)^n
      v_i ← omega*v_i + c1*r1*(p_i - x_i) + c2*r2*(g - x_i)
      v_i ← clipar(v_i, -v_max, v_max)
      x_i ← clipar(x_i + v_i, x_min, x_max)

      se f(x_i) < f(p_i):
        p_i ← x_i
        se f(x_i) < f(g): g ← x_i

  retorna g
```

1.7 Parâmetros do PSO

Parâmetro	Valor típico	Papel e guia de ajuste
N_p	20–50	$N_p = 30$ é ponto de partida robusto para a maioria dos problemas; reduzir se avaliação de f for cara
ω	0,729 fixo ou $[0.4, 0.9]$ var.	Fixo com fator de constrição: garantia teórica. Variável: mais flexível, sem garantia formal
c_1, c_2	1,496 (Clerc) ou $c_1 = c_2 = 2.0$	Equilíbrio cognitivo/social. $c_1 > c_2$: mais exploração individual; $c_2 > c_1$: convergência social mais rápida
$v_{\max}$	$0.1(x_{\max} - x_{\min})/\text{dim}$	Limita velocidade para evitar saltos excessivos. Muito alto: explosão; muito baixo: busca local excessiva
Topologia	gbest ou lbest $k = 2$	gbest: rápido em paisagens suaves; lbest: robusto em multimodal

Table 1: Parâmetros do PSO e guia de calibração.

2 Estudo de Caso: PSO nos Benchmarks CEC

O PSO é um algoritmo contínuo por natureza — suas equações de movimento pressupõem um espaço vetorial real. A comparação natural é portanto com AG e DE nas funções benchmark da Aula 5, usando o mesmo protocolo experimental (NFE = 50 000, 30 execuções, $n = 10$ dimensões).

🔁 Fio Condutor — TSP e Benchmarks CEC
Esta seção fecha o quadro comparativo do Módulo 3 para problemas contínuos: AG, DE e PSO são todos avaliados nas mesmas quatro funções com o mesmo orçamento. A Seção 4 fará o mesmo para o domínio combinatório (ACO vs. SA vs. BT no TSP), completando a comparação cruzada entre os dois paradigmas.

2.1 Configuração experimental

PSO com $N_p = 30$, $T_{\max} = 1667$ iterações (totaliza NFE $= 30 \times 1667 = 50,010 \approx 50,000$), topologia gbest, ω variável $[0.4, 0.9]$, $c_1 = c_2 = 1.496$, $v_{\max} = 0.1(x_{\max} - x_{\min})$ por dimensão.

Exemplo
PSO vs. AG vs. DE nas funções f_1–f_4, $n = 10$, NFE = 50 000.

Função	Método	$\overline{f^*}$	σ_{f^*}	Melhor	Sucesso
f_1 Esfera	AG	1.2×10^{-8}	3.1×10^{-9}	4.0×10^{-9}	100%
	DE	8.3×10^{-15}	2.1×10^{-15}	2.9×10^{-15}	100%
	PSO	3.1×10^{-12}	9.4×10^{-13}	7.2×10^{-13}	100%
f_2 Rosenbrock	AG	4.82	2.14	1.23	37%
	DE	0.31	0.18	0.04	93%
	PSO	1.47	0.83	0.18	60%
f_3 Rastrigin	AG	18.7	6.2	7.9	23%
	DE	4.1	2.8	0.0	67%
	PSO	6.8	3.1	1.0	53%
f_4 Ackley	AG	1.83	0.74	0.21	40%
	DE	0.12	0.09	0.00	87%
	PSO	0.41	0.21	0.02	73%

Table 2: Comparação AG vs. DE vs. PSO nas quatro funções benchmark (30 execuções, NFE = 50 000). "Sucesso" = $f^* \leq 0.1$ (exceto Esfera: $f^* \leq 10^{\{-6\}}$).

A DE mantém a liderança em f_2 (Rosenbrock) e f_3 (Rastrigin), onde a perturbação diferencial explora correlações entre variáveis. O PSO supera o AG em todas as funções e é competitivo com a DE em f_4 (Ackley), onde a estrutura de bacia larga com oscilações locais favorece o mecanismo de atração social — partículas próximas ao mínimo global "puxam" o enxame eficientemente.

Em f_1 (Esfera), todos convergem mas com precisão distinta: DE $\succ$ PSO $\succ$ AG. A diferença é estatisticamente significativa (Friedman $p < 10^{\{-4\}}$) mas operacionalmente irrelevante — os três encontram o ótimo. Em f_2 e f_3, a superioridade da DE sobre o PSO é estatisticamente significativa ao nível 1% (Wilcoxon).

Diagnóstico de convergência: o PSO com topologia gbest converge mais rapidamente que a DE nas primeiras 100 iterações em todas as funções — reflexo da pressão social que concentra o enxame rapidamente. O problema é que essa convergência prematura pode prender o enxame em ótimos locais, especialmente em f_3 e f_4. A topologia lbest atenua esse efeito ao custo de convergência mais lenta.

3 Otimização por Colônia de Formigas (ACO)

3.1 Motivação: estigmergia e inteligência coletiva

O **ACO** (*Ant Colony Optimization*) foi proposto por Dorigo, Maniezzo e Colorni em 1991–1992, inspirado no comportamento de formigas reais ao encontrar caminhos entre o formigueiro e fontes de alimento. Formigas individuais têm capacidade cognitiva mínima, mas a colônia como um todo resolve problemas de roteamento de forma eficiente por meio de **estigmergia**: comunicação indireta via modificação do ambiente.

O mecanismo é simples: formigas que encontram rotas curtas completam o trajeto mais vezes por unidade de tempo, depositando mais feromônio. O feromônio atrai outras formigas, que tendem a

seguir as trilhas mais marcadas, depositando ainda mais feromônio nelas. Esse ciclo de reforço positivo emerge naturalmente a partir de comportamentos locais simples — e o ACO o reproduce computacionalmente.

> **Definição — Estigmergia**
> **Estigmergia** é a forma de comunicação indireta em que agentes modificam o ambiente, e essas modificações influenciam o comportamento de outros agentes. No ACO, o feromônio é o meio de comunicação; a trilha de feromônio é o ambiente compartilhado; a intensidade do feromônio é a "memória coletiva" do histórico de boas soluções. Diferentemente da memória da Busca Tabu (proibitiva) e do SA (inexistente), a memória do ACO é **atrativa e acumulativa**.

3.2 Estrutura matemática do ACO

O ACO opera sobre um **grafo de construção** $G = (\mathcal{V}, \mathcal{E})$ onde $\mathcal{V}$ são os componentes de solução (nós) e $\mathcal{E}$ são as transições permitidas. Cada aresta (i, j) tem:

- **Feromônio** τ_{ij}: memória de longo prazo sobre a qualidade histórica de usar a transição (i, j).
- **Heurística** η_{ij}: informação a priori sobre a qualidade local de (i, j), independente da execução.

A probabilidade de uma formiga no nó i escolher ir para o nó j é:

$$p_{ij} = \frac{\tau_{ij}^{\alpha} \eta_{ij}^{\beta}}{\sum_{k \in \mathcal{N}(i)} \tau_{ik}^{\alpha} \eta_{ik}^{\beta}}$$

onde α controla a importância do feromônio (memória coletiva), β controla a importância da heurística (conhecimento local), e $\mathcal{N}(i)$ são os nós alcançáveis a partir de i ainda não visitados pela formiga corrente.

3.3 Atualização de feromônio

Após todas as m formigas construírem suas soluções, o feromônio é atualizado em duas etapas:

Evaporação: todo o feromônio é reduzido por um fator $1 - \rho$, onde $\rho \in (0, 1)$ é a taxa de evaporação:

$$\tau_{ij} \leftarrow (1 - \rho)\tau_{ij}$$

A evaporação é o mecanismo de **esquecimento**: evita que caminhos históricos acumulem feromônio indefinidamente e dominem a busca mesmo quando deixam de ser relevantes.

Depósito: as formigas que encontraram boas soluções depositam feromônio proporcional à qualidade:

$$\tau_{ij} \leftarrow \tau_{ij} + \sum_{k=1}^{m} \Delta\tau_{ij}^{k}$$

onde $\Delta\tau_{ij}^{k} = \frac{Q}{L^k}$ se a formiga k usou a aresta (i, j) em sua solução de comprimento L^k, e 0 caso contrário.

3.4 Variantes principais: ACS e MMAS

ACS (Ant Colony System, Dorigo & Gambardella, 1997). A principal variante de alto desempenho. Introduz três modificações: (1) regra de transição pseudo-aleatória — com probabilidade q_0 a formiga escolhe deterministicamente o melhor nó (explotação), e com probabilidade $1 - q_0$ usa a probabilidade

proporcional (exploração); (2) atualização local de feromônio durante a construção, que reduz levemente o feromônio das arestas usadas, incentivando diversidade; (3) apenas a melhor formiga global deposita feromônio no final de cada iteração.

MMAS (MAX-MIN Ant System, Stützle & Hoos, 2000). Limita o feromônio ao intervalo $[\tau_{\min}, \tau_{\max}]$, prevenindo estagnação prematura. Apenas a melhor formiga ou a melhor da iteração deposita feromônio. O $\tau_{\min}$ é calculado teoricamente como função de $\tau_{\max}$ e do tamanho do problema.

Aspecto	ACS	MMAS
Regra de transição	Pseudo-aleatória (parâmetro q_0)	Probabilística com limites de τ
Depósito	Apenas melhor global	Melhor global ou da iteração
Prevenção de estagnação	Atualização local durante construção	Limites $[\tau_{\min}, \tau_{\max}]$
Parâmetros	q_0, α, β, ρ, m	α, β, ρ, m, $\tau_{\max}$
Pontos fortes	Alta explotação; bom em instâncias pequenas	Melhor exploração; robusto em instâncias grandes

Table 3: Comparação entre ACS e MMAS.

3.5 Algoritmo MMAS

Algoritmo — MAX-MIN Ant System (MMAS)

```
MMAS(grafo G, m, alpha, beta, rho, N_iter):
  tau_max ← 1 / (rho * f(solucao_gulosa))
  tau_min ← tau_max / (2n)
  tau_ij  ← tau_max  para toda (i,j) ∈ E

  melhor_global ← NIL

  para it = 1 até N_iter:
    para k = 1 até m:
      s_k ← construir_solucao(G, tau, eta, alpha, beta)
      avaliar f(s_k)

    melhor_iter ← argmin_k f(s_k)
    se f(melhor_iter) < f(melhor_global):
      melhor_global ← melhor_iter

    tau_ij ← (1 - rho) * tau_ij  para toda (i,j)

    // alterna entre exploração (iter. inicial) e explotação (final)
    se it < N_iter / 2:
      formiga_ref ← melhor_iter
    senão:
      formiga_ref ← melhor_global
    para (i,j) ∈ solucao(formiga_ref):
      tau_ij ← tau_ij + 1 / f(formiga_ref)

    tau_ij ← max(tau_min, min(tau_max, tau_ij))  para toda (i,j)
```

```
retorna melhor_global
```

4 Estudo de Caso: ACO no TSP

O TSP é o problema para o qual o ACO foi originalmente concebido. Dorigo criou o primeiro algoritmo ACO — o *Ant System* — especificamente para o TSP em 1992, e todas as variantes subsequentes (ACS, MMAS) foram validadas primariamente nesse domínio. A aplicação é portanto a mais natural possível.

4.1 Mapeamento TSP → ACO

Grafo de construção: o grafo completo das n cidades — $G = (\mathcal{V}, \mathcal{E})$ com $|\mathcal{V}| = n$ e $|\mathcal{E}| = \frac{n(n-1)}{2}$.

Feromônio τ_{ij}: intensidade associada ao arco (i, j). Inicializado com $\tau_0 = \frac{1}{n \cdot L_{\text{nn}}}$ onde L_{nn} é o comprimento do tour obtido pela heurística do vizinho mais próximo — uma estimativa razoável do ótimo.

Heurística $\eta_{ij} = \frac{1}{d_{ij}}$: arcos curtos são preferidos a priori. Parâmetros típicos: $\alpha = 1$, $\beta = 2$–5 (heurística mais importante que feromônio inicialmente).

Construção de tour: cada formiga começa em uma cidade aleatória e constrói um tour completo usando a probabilidade p_{ij}, com a restrição de não visitar cidades já visitadas (*lista tabu* local por construção).

Melhoria local 2-opt: é prática padrão no ACO para TSP aplicar uma busca local 2-opt a cada tour construído antes da atualização de feromônio. Isso melhora dramaticamente a qualidade sem aumentar o número de avaliações de f.

🔁 Fio Condutor — TSP e Benchmarks CEC
O operador 2-opt do ACO é exatamente o mesmo que define a vizinhança da Busca Tabu (Aula 4). A diferença é que na BT o 2-opt é aplicado iterativamente com memória explícita; no ACO ele é aplicado uma vez a cada tour construído, como refinamento local de uma solução gerada por construção probabilística. Essa combinação — construção global por feromônio + refinamento local por 2-opt — é o modelo híbrido mais eficaz para o TSP na literatura.

4.2 Resultados comparativos

Exemplo
TSP com $n = 30$ cidades (mesma instância das Aulas 3 e 4, coordenadas uniformes em $[0, 100]^2$, semente registrada).

MMAS configurado com $m = 10$ formigas, $\alpha = 1$, $\beta = 3$, $\rho = 0.1$, 500 iterações (NFE $= 10 \times 500 = 5000$ construções + melhoria 2-opt em cada). Comparação com os métodos das Aulas 3–4 usando o mesmo orçamento em termos de chamadas ao 2-opt.

Método	$\overline{f^*}$ (km)	σ_{f^*}	Melhor	NFE
HC · 100 reinícios	912	48	841	21 000
SA ($\alpha = 0.95$)	848	21	819	146 000
BT completa	818	8	806	58 000
ACO/MMAS + 2-opt	809	6	801	≈ 58 000

Table 4: Comparação de métodos no TSP com $n = 30$ cidades (30 execuções independentes).

O ACO com melhoria 2-opt é competitivo com a BT completa, atingindo qualidade similar com variância ligeiramente menor. A diferença entre ACO e BT não é estatisticamente significativa ao nível 5% (Wilcoxon $p = 0.12$) — resultado coerente com o NFL: dois métodos bem calibrados para o mesmo problema tendem a convergir para desempenhos equivalentes.

A vantagem do ACO sobre o SA é clara e estatisticamente significativa ($p = 0.0003$): a memória coletiva de feromônio permite que a colônia identifique e reforce gradualmente os arcos que pertencem a tours de alta qualidade, enquanto o SA reexplora o espaço de forma essencialmente sem memória.

Análise do feromônio: ao final das 500 iterações, os arcos com $\tau_{ij} > 0.8\tau_{\max}$ correspondem a $>$ 85% dos arcos presentes na melhor solução encontrada — evidência de que o feromônio convergiu para representar corretamente a estrutura do tour ótimo. Esse fenômeno de "aprendizado estrutural" é a propriedade mais distintiva do ACO em relação aos outros algoritmos do módulo.

5 Síntese do Módulo 3: comparação dos algoritmos populacionais

Encerramos o Módulo 3 com uma visão integrada dos quatro algoritmos estudados.

Aspecto	AG	DE	PSO	ACO
Espaço natural	Discreto, misto, real	Contínuo	Contínuo	Combinatório
Memória	Implícita (genoma)	Implícita (pop.)	Explícita ($\boldsymbol{p}_i$, $\boldsymbol{g}$)	Explícita (feromônio)
Tipo de memória	Soluções completas	Vetores de perturbação	Melhores posições	Atributos de arcos
Parâmetros críticos	N_p, p_c, p_m	F, C_R	ω, c_1, c_2	α, β, ρ, m
Facilidade de calibração	Moderada	Baixa	Baixa (Clerc)	Moderada
Forte em	Problemas mistos, representação flexível	Contínuo multimodal com correlações	Contínuo suave, convergência rápida	Combinatório com grafo natural
Fraco em	Contínuo alta dimensão	Combinatório	Combinatório	Contínuo
Custo por iteração	N_p aval.	N_p aval.	N_p aval.	m aval. (tipicamente $m < N_p$)

Table 5: Comparação dos algoritmos populacionais do Módulo 3.

Lição central: não existe hierarquia universal — o NFL continua válido. Em problemas contínuos, DE $\approx$ PSO $\succ$ AG na maioria das paisagens testadas, mas a diferença desaparece em instâncias específicas (como f_1). Em problemas combinatórios com estrutura de grafo, ACO e BT são os métodos de referência, com ACO tendo a vantagem adicional do "aprendizado estrutural" por feromônio.

Problemas mistos (variáveis contínuas e discretas simultaneamente) são o domínio onde AGs com representação híbrida ou hibridizações (PSO + SA, ACO + BT) tendem a ser mais eficazes do que qualquer método puro.

No **Módulo 4**, passamos para otimização multiobjetivo — o caso onde há dois ou mais objetivos conflitantes a otimizar simultaneamente. O conceito central é a **fronteira de Pareto**, e o algoritmo de referência é o **NSGA-II**, que estende o AG com um mecanismo de ranqueamento por dominância.

6 Exercícios

Exercício

1 (Estabilidade do PSO). Para o PSO com $c_1 = c_2 = 2.05$ e $\omega = 0.729$ (configuração de Clerc), verifique analiticamente que a condição de estabilidade é satisfeita. Em seguida, implemente o PSO em Python e compare a curva de convergência (30 execuções) para Rastrigin 10D com: (a) os parâmetros de Clerc; (b) $\omega = 1.5$ (instável). O que ocorre com o valor de $\boldsymbol{g}$ ao longo das iterações no caso instável? Plote as trajetórias de duas partículas para visualizar o comportamento divergente.

Exercício

2 (Topologia do enxame). Para Rastrigin 10D (NFE = 50 000, 30 execuções), compare PSO com topologia gbest e lbest ($k = 2$). (a) Plote as curvas de convergência com IC 95%. (b) Em qual geração

as curvas começam a divergir? (c) A diferença é estatisticamente significativa (Wilcoxon)? (d) Repita para f_1 (Esfera). A vantagem do lbest se mantém em problemas unimodais? Por quê?

Exercício

3 (ACO para o TSP). Implemente o MMAS para o TSP com $n = 30$ cidades (mesma instância do Exercício 4 da Aula 3). (a) Execute sem melhoria 2-opt e compare com a versão com 2-opt (30 execuções cada, mesmo NFE total). Qual é o impacto do 2-opt na qualidade final e na variância? (b) Varie $\beta \in \{1, 2, 5, 10\}$ e plote o custo médio em função de β. Existe um valor ótimo? O que ocorre quando β é muito alto (heurística domina o feromônio)?

Exercício

4 (Comparação completa — Módulo 3). Reproduza e estenda a Table 4 adicionando AG com representação permutacional (cruzamento OX, mutação por inversão de segmento) ao TSP com $n = 30$ cidades. Use 30 execuções independentes e o mesmo orçamento NFE para todos os métodos. (a) Aplique o teste de Friedman sobre os cinco métodos (HC, SA, BT, ACO, AG); use Nemenyi como post-hoc e produza um diagrama de diferença crítica. (b) O AG permutacional supera o SA? Supera a BT? Discuta por que o ACO e a BT tendem a superar o AG no TSP à luz dos mecanismos de cada algoritmo.

Leituras recomendadas:

• Kennedy, J., Eberhart, R. Particle swarm optimization. **Proc. IEEE ICNN**, 1942–1948, 1995. *(artigo original do PSO)*
• Clerc, M., Kennedy, J. The particle swarm — Explosion, stability, and convergence in a multidimensional complex space. **IEEE Transactions on Evolutionary Computation**, 6(1), 58–73, 2002. *(análise de estabilidade — leitura obrigatória)*
• Dorigo, M., Gambardella, L. M. Ant colony system: A cooperative learning approach to the traveling salesman problem. **IEEE Transactions on Evolutionary Computation**, 1(1), 53–66, 1997.
• Stützle, T., Hoos, H. H. MAX-MIN ant system. **Future Generation Computer Systems**, 16(8), 889–914, 2000.
• Dorigo, M., Stützle, T. **Ant Colony Optimization**. MIT Press, 2004. *(referência completa do ACO — caps. 2–4)*