Metaheurísticas

Aula 7 — Fundamentos de Otimização Multiobjetivo e NSGA-II

Raoni F. S. Teixeira · 1s/2026

Objetivos desta aula

Ao final desta aula, o aluno deve ser capaz de:

1. Formular problemas com múltiplos objetivos conflitantes e identificar por que a escalarização ingênua é inadequada;
2. Definir dominância de Pareto, fronteira de Pareto e conjunto de Pareto com precisão formal;
3. Descrever o mecanismo completo do NSGA-II — ordenação por dominância, distância de agrupamento e operadores genéticos — e implementá-lo;
4. Calcular e interpretar as métricas de qualidade de fronteiras de Pareto: hipervolume, spread e IGD;
5. Aplicar o NSGA-II às funções benchmark ZDT e comparar com escalarização por soma ponderada, identificando casos onde a escalarização falha estruturalmente.

1 Por que múltiplos objetivos?

Todos os problemas estudados até aqui tinham um único critério de qualidade: minimizar custo, minimizar distância, minimizar erro. Essa simplificação é conveniente matematicamente, mas raramente reflete a realidade de problemas de engenharia.

Na prática, o engenheiro opera com objetivos **conflitantes** que não podem ser otimizados simultaneamente. Minimizar custo e maximizar qualidade são objetivos que se opõem em praticamente qualquer domínio — logística, manufatura, projeto estrutural, sistemas de energia. Reduzir o tempo de entrega aumenta o custo operacional. Aumentar a confiabilidade de um sistema requer redundância que eleva o investimento. Minimizar emissões pode conflitar com minimizar custos quando as fontes mais limpas têm custo marginal mais alto.

A abordagem clássica — **escalarização** — combina os objetivos em uma soma ponderada:

$$f_{\text{esc}(\boldsymbol{x})} = \sum_k w_k f_{k(\boldsymbol{x})}, \quad \sum_k w_k = 1, \quad w_k \geq 0$$

Isso reduz o problema a um único objetivo e permite usar qualquer método do curso. Mas tem limitações sérias:

- Os pesos w_k precisam ser definidos **a priori**, antes de conhecer o espaço de soluções possíveis.
- Para fronteiras de Pareto **não-convexas** ou **descontínuas**, nenhuma escolha de pesos alcança certas regiões — partes da fronteira ficam estruturalmente inacessíveis.
- Uma única execução produz **um** ponto de compromisso; o decisor não vê o espectro completo de soluções possíveis.

A abordagem multiobjetivo resolve esses problemas: em vez de uma solução, busca-se um **conjunto** de soluções que representa o espectro completo de compromissos possíveis — a **fronteira de Pareto**.

2 Fundamentos Teóricos

2.1 Formulação geral

Definição — Problema de Otimização Multiobjetivo (POM)
Dado um vetor de variáveis de decisão $\boldsymbol{x} \in \mathcal{F} \subseteq \mathbb{R}^n$ e m funções objetivo $f_1, ..., f_m : \mathcal{F} \to \mathbb{R}$, o POM é:

$$\min_{\boldsymbol{x} \in \mathcal{F}} \quad \boldsymbol{f}(\boldsymbol{x}) = \left(f_1(\boldsymbol{x}), f_2(\boldsymbol{x}), ..., f_{m(\boldsymbol{x})}\right)$$

O **espaço de objetivos** $\mathcal{Z} = \{\boldsymbol{f}(\boldsymbol{x}) : \boldsymbol{x} \in \mathcal{F}\} \subseteq \mathbb{R}^m$ é a imagem do espaço viável sob o mapeamento $\boldsymbol{f}$.

A palavra "min" no POM não tem o mesmo significado que na otimização mono-objetivo: não existe, em geral, um $\boldsymbol{x}^*$ que minimize **todos** os objetivos simultaneamente. A noção de "ótimo" precisa ser redefinida.

2.2 Dominância de Pareto

Definição — Dominância de Pareto
Uma solução $\boldsymbol{x}$ **domina** $\boldsymbol{y}$ (escrito $\boldsymbol{x} \prec \boldsymbol{y}$) se e somente se:

$$f_{k(\boldsymbol{x})} \leq f_{k(\boldsymbol{y})} \quad \forall k \in \{1, ..., m\}$$

e

$$\exists j \in \{1, ..., m\} : f_{j(\boldsymbol{x})} < f_{j(\boldsymbol{y})}$$

Ou seja, $\boldsymbol{x}$ é ao menos tão boa quanto $\boldsymbol{y}$ em **todos** os objetivos, e estritamente melhor em **pelo menos um**.

A dominância define uma ordem parcial sobre $\mathcal{F}$: duas soluções podem ser **incomparáveis** (nenhuma domina a outra) quando cada uma é melhor em pelo menos um objetivo. Essa incomparabilidade representa um compromisso legítimo entre objetivos conflitantes.

Definição — Conjunto e Fronteira de Pareto
O **conjunto de Pareto** $\mathcal{P}^* \subseteq \mathcal{F}$ é o conjunto de todas as soluções não-dominadas:

$$\mathcal{P}^* = \{\boldsymbol{x} \in \mathcal{F} : \nexists \boldsymbol{y} \in \mathcal{F} \text{ tal que } \boldsymbol{y} \prec \boldsymbol{x}\}$$

A **fronteira de Pareto** $\mathcal{PF}^* = \boldsymbol{f}(\mathcal{P}^*) \subseteq \mathcal{Z}$ é a imagem do conjunto de Pareto no espaço de objetivos.

Exemplo
Compromisso custo vs. qualidade — caso genérico com três soluções. Dois objetivos a minimizar: f_1 = custo de implementação e f_2 = erro residual (menor = melhor qualidade).

Solução	f_1 (custo)	f_2 (erro)	Status
A	10	80	Não-dominada
B	40	40	Não-dominada
C	80	10	Não-dominada
D	50	70	Dominada por B: $f_1(B) < f_1(D)$ e $f_2(B) < f_2(D)$
E	60	50	Dominada por B e C

Table 1: Dominância em um problema genérico de dois objetivos.

As soluções A, B e C são mutuamente incomparáveis — cada uma é melhor em pelo menos um objetivo. Juntas formam a fronteira de Pareto. D e E são dominadas e seriam descartadas. A escolha entre A, B e C depende das preferências do decisor, que agora tem visibilidade do espectro completo de compromissos antes de decidir.

2.3 Ponto ideal e ponto nadir

Dois pontos de referência estruturam o espaço de objetivos:

- **Ponto ideal** $\boldsymbol{z}^*$: componente $z_k^* = \min_{\boldsymbol{x}\in\mathcal{F}} f_{k(\boldsymbol{x})}$ — o melhor valor possível de cada objetivo, otimizado individualmente. Geralmente inatingível simultaneamente.
- **Ponto nadir** $\boldsymbol{z}^{\text{nad}}$: componente $z_k^{\text{nad}} = \max_{\boldsymbol{x}\in\mathcal{P}^*} f_{k(\boldsymbol{x})}$ — o pior valor de cada objetivo ao longo da fronteira de Pareto.

Esses dois pontos definem o **espaço de objetivos relevante**: a caixa $[\boldsymbol{z}^*, \boldsymbol{z}^{\text{nad}}]$ que contém toda a fronteira de Pareto. São usados para normalizar os objetivos antes de calcular métricas de qualidade.

3 NSGA-II

O **NSGA-II** (*Non-dominated Sorting Genetic Algorithm II*) foi proposto por Deb, Pratap, Agarwal e Meyarivan em 2002 e tornou-se o algoritmo de referência em otimização multiobjetivo evolutiva. Sua elegância reside em dois mecanismos principais — **ordenação por não-dominância** e **distância de agrupamento** — que juntos guiam a população em direção à fronteira de Pareto mantendo diversidade ao longo dela.

3.1 Ordenação por não-dominância

O procedimento classifica a população inteira em **frontes de Pareto** $F_1, F_2, \ldots$:

- **Fronte 1** (F_1): soluções não-dominadas por nenhuma outra da população.
- **Fronte 2** (F_2): soluções não-dominadas após remover F_1.
- **Fronte** $\boldsymbol{k}$: soluções não-dominadas após remover $F_1, \ldots, F_{k-1}$.

Para cada solução p, calculam-se dois atributos:
- n_p: número de soluções que dominam p (grau de dominância). A solução pertence a F_1 se e somente se $n_p = 0$.
- S_p: conjunto de soluções dominadas por p.

O algoritmo de Deb realiza essa ordenação em $O(mN^2)$ operações, onde m é o número de objetivos e N o tamanho da população.

3.2 Distância de agrupamento

Dentro de um mesmo fronte F_k, como comparar duas soluções para decidir qual manter? A **distância de agrupamento** $I_{\text{dist}(i)}$ mede a densidade de soluções ao redor da solução i no espaço de objetivos:

$$I_{\text{dist}(i)} = \sum_{k=1}^{m} \frac{f_{k(i+1)} - f_{k(i-1)}}{f_k^{\max} - f_k^{\min}}$$

onde $i+1$ e $i-1$ são os vizinhos imediatos de i quando as soluções do fronte são ordenadas pelo objetivo k, e a normalização pelo range garante que todos os objetivos contribuam igualmente. Soluções nos extremos da fronteira recebem $I_{\text{dist}} = +\infty$.

Soluções com **maior** distância de agrupamento são preferidas: indicam regiões menos densamente amostradas da fronteira, promovendo diversidade.

3.3 Operador de seleção por dominância ($\underset{n}{\prec}$)

O NSGA-II usa torneio binário baseado na relação de ordem $\underset{n}{\prec}$:

$$\boldsymbol{x} \underset{n}{\prec} \boldsymbol{y} \Leftrightarrow \begin{cases} \text{rank}(\boldsymbol{x}) < \text{rank}(\boldsymbol{y}) & \text{(fronte melhor)} \\ \text{rank}(\boldsymbol{x}) = \text{rank}(\boldsymbol{y}) \text{ e } I_{\text{dist}(\boldsymbol{x})} > I_{\text{dist}(\boldsymbol{y})} & \text{(mesma fronte, menos denso)} \end{cases}$$

Isso integra qualidade (fronte) e diversidade (agrupamento) em um único critério de seleção — sem pesos ou parâmetros adicionais.

3.4 Algoritmo completo

Algoritmo — NSGA-II

```
NSGA-II(f_1..f_m, N, T_max, p_c, p_m):
  P_0 ← população aleatória de tamanho N
  avaliar f_k(x) para todo x ∈ P_0 e todo k
  Q_0 ← gerar_filhos(P_0, p_c, p_m)   // cruzamento SBX + mutação polinomial

  para t = 1 até T_max:
    R_t ← P_{t-1} ∪ Q_{t-1}           // combina pais e filhos (2N indivíduos)
    F ← fast_non_dominated_sort(R_t)   // F = {F_1, F_2, ...}
    P_t ← {}
    i ← 1
    enquanto |P_t| + |F_i| ≤ N:
      calcular_crowding_distance(F_i)
      P_t ← P_t ∪ F_i
      i ← i + 1
    // preenche P_t com melhores de F_i pelo crowding
    ordenar F_i por I_dist decrescente
    P_t ← P_t ∪ F_i[1 : N - |P_t|]

    Q_t ← gerar_filhos(P_t, p_c, p_m) // torneio com <_n
```

```
retorna F_1
```

O passo crítico é a formação de $R_t = P_{t-1} \cup Q_{t-1}$ com $2N$ indivíduos. Ao selecionar os N melhores de R_t — priorizando frontes menores e, dentro do mesmo fronte, maior distância de agrupamento — o NSGA-II garante **elitismo multiobjetivo**: boas soluções nunca são descartadas.

Observação
Complexidade computacional. A ordenação por não-dominância custa $O(mN^2)$ por geração; o cálculo de distâncias de agrupamento custa $O(mN \log N)$. O custo total é $O(mN^2 T_{\max})$. Para $N = 100, m = 2, T_{\max} = 200$: $\approx 4 \times 10^6$ comparações de dominância — perfeitamente viável em qualquer linguagem moderna.

4 Métricas de Qualidade de Fronteiras de Pareto

Avaliar algoritmos multiobjetivo exige métricas que capturem **dois** aspectos simultaneamente: **convergência** (quão próxima a fronteira aproximada está da fronteira verdadeira) e **diversidade** (quão uniformemente as soluções cobrem a fronteira).

4.1 Hipervolume (HV)

Definição — Hipervolume
Dado um conjunto de soluções $A = \{\boldsymbol{z}^1, \ldots, \boldsymbol{z}^k\} \subseteq \mathbb{R}^m$ no espaço de objetivos e um **ponto de referência** $\boldsymbol{r} \in \mathbb{R}^m$ dominado por todas as soluções de A, o **hipervolume** de A é o volume da união dos hipercubos formados por cada $\boldsymbol{z}^i$ e $\boldsymbol{r}$:

$$\mathrm{HV}(A, \boldsymbol{r}) = \lambda_m \bigcup_{i=1}^{k} \left[\boldsymbol{z}^i, \boldsymbol{r}\right]$$

onde λ_m é a medida de Lebesgue m-dimensional.

Um HV maior indica fronteira de melhor qualidade — mais próxima da fronteira ótima e/ou mais diversificada. Para $m = 2$, o cálculo é $O(N \log N)$ (ordenação + varredura). Para $m > 3$, o problema é NP-difícil e usa-se estimativa por Monte Carlo.

4.2 Spread (Δ)

O **spread** mede a uniformidade da distribuição das soluções ao longo da fronteira aproximada:

$$\Delta = \frac{d_f + d_l + \sum_{i=1}^{N-1} |d_i - \overline{d}|}{d_f + d_l + (N-1)\overline{d}}$$

onde d_i é a distância Euclidiana entre soluções consecutivas na fronteira, $\overline{d}$ é a média dessas distâncias, e d_f, d_l são as distâncias dos extremos da fronteira aproximada aos extremos da fronteira de referência. $\Delta = 0$ indica distribuição perfeitamente uniforme.

4.3 GD e IGD

Generational Distance (GD): distância média das soluções encontradas à fronteira de referência — mede convergência pura:

$$\mathrm{GD}(A, \mathcal{PF}^*) = \frac{1}{|A|} \sum_{\boldsymbol{z} \in A} \min_{\boldsymbol{z}^* \in \mathcal{PF}^*} \| \boldsymbol{z} - \boldsymbol{z}^* \|_2$$

Inverted Generational Distance (IGD): distância média dos pontos da fronteira de referência às soluções encontradas — mede convergência **e** diversidade:

$$\mathrm{IGD}(A, \mathcal{PF}^*) = \frac{1}{|\mathcal{PF}^*|} \sum_{\boldsymbol{z}^* \in \mathcal{PF}^*} \min_{\boldsymbol{z} \in A} \| \boldsymbol{z}^* - \boldsymbol{z} \|_2$$

O IGD é preferido ao GD porque penaliza tanto má convergência quanto má cobertura da fronteira. Um conjunto A com uma única solução excelente teria GD baixo mas IGD alto — corretamente penalizado pelo IGD.

> ⚠️ **Atenção**
> As métricas HV, Δ e IGD devem sempre ser calculadas com uma **fronteira de referência** de alta qualidade — idealmente a fronteira de Pareto analítica, ou a melhor aproximação disponível. Em problemas sem fronteira analítica, usa-se a fronteira formada pela união de todas as soluções não-dominadas obtidas por **todos** os algoritmos em comparação. Comparações com fronteiras de referência distintas são inválidas.

5 Estudo de Caso: Benchmarks ZDT

As funções **ZDT** (Zitzler-Deb-Thiele, 2000) são o conjunto de referência para avaliar algoritmos multi-objetivo. Sua importância reside em ter **fronteiras de Pareto analíticas conhecidas**, o que permite calcular métricas de qualidade exatas — sem a incerteza de fronteiras de referência aproximadas. Cada função foi projetada para desafiar um aspecto específico dos algoritmos.

> 🔁 **Fio Condutor — Benchmarks ZDT**
> Os benchmarks ZDT são para otimização multiobjetivo o que as funções CEC são para mono-objetivo: um conjunto mínimo e padronizado que cobre os casos estruturalmente distintos. O NSGA-II será avaliado em ZDT1 (fronteira convexa), ZDT2 (fronteira côncava) e ZDT3 (fronteira descontínua) — esta última sendo o caso onde a escalarização por soma ponderada falha estruturalmente, independentemente dos pesos escolhidos.

5.1 As três funções de referência

Todas definidas com $\boldsymbol{x} \in [0,1]^n$, $n = 30$, dois objetivos ($m = 2$):

ZDT1 — Fronteira convexa:

$$f_1(\boldsymbol{x}) = x_1, \quad g(\boldsymbol{x}) = 1 + \frac{9}{n-1} \sum_{i=2}^{n} x_i, \quad f_2(\boldsymbol{x}) = g1 - \sqrt{\frac{f_1}{g}}$$

Fronteira de Pareto ótima: $g = 1$, $f_2 = 1 - \sqrt{f_1}$, $f_1 \in [0,1]$. Curva convexa contínua.

ZDT2 — Fronteira côncava:

$$f_1(\boldsymbol{x}) = x_1, \quad g(\boldsymbol{x}) = 1 + \frac{9}{n-1}\sum_{i=2}^{n} x_i, \quad f_2(\boldsymbol{x}) = g1 - \left(\frac{f_1}{g}\right)^2$$

Fronteira de Pareto ótima: $g = 1$, $f_2 = 1 - f_1^2$, $f_1 \in [0, 1]$. Curva côncava — inacessível por escalarização com pesos uniformes.

ZDT3 — Fronteira descontínua:

$$f_1(\boldsymbol{x}) = x_1, \quad g(\boldsymbol{x}) = 1 + \frac{9}{n-1}\sum_{i=2}^{n} x_i, \quad f_2(\boldsymbol{x}) = g1 - \sqrt{\frac{f_1}{g}} - \left(\frac{f_1}{g}\right)\sin(10\pi f_1\Bigg)$$

Fronteira de Pareto ótima: $g = 1$, cinco segmentos descontínuos em $f_1 \in [0, 1]$. Este é o caso crítico: a escalarização por soma ponderada é **estruturalmente incapaz** de encontrar soluções nas lacunas entre os segmentos, independentemente dos pesos.

5.2 Por que ZDT3 é o caso diagnóstico crítico

A escalarização $m \in wf_1 + (1-w)f_2$ busca o ponto da fronteira onde a linha de nível $wf_1 + (1-w)f_2 = c$ é tangente à fronteira. Para uma fronteira convexa (ZDT1), qualquer ponto é alcançável com algum w. Para uma fronteira descontínua (ZDT3), os pontos nas lacunas entre segmentos nunca são tangenciados por nenhuma linha de nível — são estruturalmente inacessíveis. Isso não é uma limitação do algoritmo de escalarização, mas uma **limitação matemática fundamental** da abordagem de soma ponderada.

> **Definição — Fronteira de Pareto inacessível por escalarização**
> Um ponto $\boldsymbol{z} \in \mathcal{PF}^*$ é **inacessível por escalarização linear** se não existe $\boldsymbol{w} > .' = 0$ com $\sum_k w_k = 1$ tal que $\boldsymbol{z} = \arg\min_{\{\boldsymbol{z}' \in \mathcal{PF}^*\}} \sum_k w_k z'_k$. Isso ocorre em toda região côncava ou descontinuidade da fronteira de Pareto. Métodos baseados em população como o NSGA-II não sofrem dessa limitação.

5.3 Protocolo experimental e resultados

NSGA-II com $N = 100$, $T_{\max} = 250$ gerações (NFE $= 25,000$), cruzamento SBX ($\eta_c = 20$, $p_c = 0.9$), mutação polinomial ($\eta_m = 20$, $p_m = \frac{1}{n}$), 30 execuções independentes.

Escalarização: AG mono-objetivo (Aula 5) aplicado separadamente para cada um de 20 vetores de peso $\boldsymbol{w}$ uniformemente espaçados em $[0, 1]$, mesmo NFE total por vetor de peso.

> **Exemplo**
> **NSGA-II vs. escalarização nas funções ZDT, $n = 30$.**

Função	Método	IGD (médio)	HV (médio)	Δ (médio)
ZDT1	NSGA-II	2.1×10^{-3}	0.861	0.38
	Escalarização	4.8×10^{-3}	0.847	0.51
ZDT2	NSGA-II	3.4×10^{-3}	0.579	0.41
	Escalarização	0.21	0.441	0.89
ZDT3	NSGA-II	4.7×10^{-3}	0.512	0.43
	Escalarização	0.38	0.301	1.00

Table 2: NSGA-II vs. escalarização nas funções ZDT (30 execuções, NFE = 25 000). Fronteira de referência analítica com 500 pontos uniformes.

Em ZDT1 (fronteira convexa), a escalarização é competitiva — HV próximo, IGD levemente inferior. A diferença não é estatisticamente significativa ao nível 5% (Wilcoxon no HV: $p = 0.08$).

Em ZDT2 (fronteira côncava), a escalarização deteriora: IGD $= 0.21$ vs. $3.4 \times 10^{\{-3\}}$ do NSGA-II — dois ordens de grandeza de diferença. A causa é que pesos intermediários geram linhas de nível que não tangenciam a curva côncava, resultando em soluções concentradas nos extremos da fronteira. O $\Delta = 0.89$ confirma cobertura extremamente não-uniforme.

Em ZDT3 (fronteira descontínua), a escalarização colapsa: $\Delta = 1.00$ indica que as 20 execuções de escalarização se concentraram em apenas 1–2 dos 5 segmentos, sem representação das regiões intermediárias. O NSGA-II, por operar com uma população que evolui **coletivamente**, mantém representantes em todos os segmentos simultaneamente — demonstrando a vantagem estrutural dos métodos populacionais multiobjetivo.

Diagnóstico visual: ao plotar as fronteiras, a diferença em ZDT3 é imediata — a escalarização produz clusters em 2 segmentos; o NSGA-II cobre todos os 5. Esse experimento deve ser reproduzido no Exercício 4.

6 Síntese e Próximos Passos

Esta aula estabeleceu os fundamentos da otimização multiobjetivo: a inadequação estrutural da escalarização para fronteiras não-convexas e descontínuas, a teoria de dominância de Pareto como substituto da noção de ótimo escalar, e o NSGA-II como algoritmo de referência que integra convergência e diversidade em um único mecanismo elegante.

A lição central dos benchmarks ZDT é que a limitação da escalarização não é algorítmica — é matemática. Nenhum refinamento do AG mono-objetivo resolverá o problema em ZDT3: a fronteira descontínua é estruturalmente inacessível por qualquer soma ponderada. Métodos populacionais multiobjetivo como o NSGA-II não sofrem essa limitação porque mantêm diversidade ao longo de toda a fronteira **durante** a evolução, não apenas ao final.

A visão prática é tão importante quanto a teórica: o resultado de um algoritmo multiobjetivo não é uma solução, mas um **conjunto** de soluções que representa compromissos. Isso desloca o papel do tomador de decisão — de definir pesos antes de otimizar para **escolher** entre soluções depois de conhecer o espectro completo de possibilidades.

Na **Aula 8**, aprofundamos os aspectos práticos: variantes (NSGA-III para $m > 3$ objetivos, MOEA/D como alternativa baseada em decomposição), hibridização com busca local para melhorar convergência, e aplicação a problemas reais com três ou mais objetivos.

7 Exercícios

Exercício
1 (Dominância de Pareto). Dado o conjunto de soluções para um problema de dois objetivos (ambos a minimizar):

$A = (2, 8)$, $B = (4, 4)$, $C = (7, 2)$, $D = (3, 7)$, $E = (5, 5)$, $F = (6, 3)$, $G = (1, 10)$

(a) Identifique todas as relações de dominância entre pares. (b) Determine o conjunto de Pareto $\mathcal{P}^*$. (c) Calcule os pontos ideal e nadir. (d) Se o decisor usa escalarização com $w_1 = 0.3$ e $w_2 = 0.7$ (após normalização min-max), qual solução é escolhida? Essa solução pertence à fronteira de Pareto?

Exercício
2 (Ordenação por não-dominância). Implemente o algoritmo de ordenação por não-dominância de Deb et al. (2002) em Python. Para uma população de 20 soluções aleatórias com $f_1(\boldsymbol{x}) = x_1$ e $f_2(\boldsymbol{x}) = x_2$, $\boldsymbol{x} \in [0, 1]^2$, execute a ordenação e plote os frontes F_1, F_2, F_3 com cores distintas. Qual é a complexidade computacional do seu algoritmo? Compare com o limite teórico de $O(mN^2)$.

Exercício
3 (Hipervolume). Para os conjuntos $A = \{(1, 4), (2, 2), (4, 1)\}$ e $B = \{(1.5, 3), (2.5, 2), (3.5, 1.5)\}$ com ponto de referência $\boldsymbol{r} = (5, 5)$: (a) Calcule HV(A) e HV(B) analiticamente (geometria 2D — soma de retângulos). (b) A tem maior HV que B? Isso implica que todas as soluções de A dominam as de B? (c) Implemente em Python o cálculo de HV para $m = 2$ e verifique seus resultados. (d) O conjunto $A \cup B$ tem HV maior que HV(A)? Por quê?

Exercício
4 (NSGA-II nas funções ZDT). Implemente o NSGA-II com cruzamento SBX ($\eta_c = 20$) e mutação polinomial ($\eta_m = 20$) para as funções ZDT1, ZDT2 e ZDT3 com $n = 30$, $N = 100$, $T_{\max} = 250$ e 30 execuções independentes.

(a) Para cada função, plote a fronteira de Pareto aproximada (mediana das execuções) sobre a fronteira analítica.

(b) Calcule IGD, HV e Δ médios e desvio padrão para cada função, usando a fronteira analítica com 500 pontos uniformes como referência.

(c) Implemente a escalarização por soma ponderada com 20 vetores de peso uniformemente espaçados. Compare visualmente e numericamente com o NSGA-II. Em quais funções a diferença é mais dramática?

(d) Para ZDT3 especificamente: quantos dos 5 segmentos da fronteira ótima o NSGA-II cobre em cada execução? E a escalarização? Isso ilustra a limitação matemática discutida na Seção 5.2.

Leituras recomendadas:

• Deb, K., Pratap, A., Agarwal, S., Meyarivan, T. A fast and elitist multiobjective genetic algorithm: NSGA-II. **IEEE Transactions on Evolutionary Computation**, 6(2), 182–197, 2002. *(artigo original — leitura obrigatória)*
• Deb, K. **Multi-Objective Optimization Using Evolutionary Algorithms**. Wiley, 2001. Caps. 1–5.
• Zitzler, E., Deb, K., Thiele, L. Comparison of multiobjective evolutionary algorithms: Empirical results. **Evolutionary Computation**, 8(2), 173–195, 2000. *(definição das funções ZDT — leitura obrigatória para este módulo)*
• Zitzler, E., Thiele, L. Multiobjective evolutionary algorithms: A comparative case study and the strength Pareto approach. **IEEE Transactions on Evolutionary Computation**, 3(4), 257–271, 1999.
• While, L., Hingston, P., Barone, L., Huband, S. A faster algorithm for calculating hypervolume. **IEEE Transactions on Evolutionary Computation**, 10(1), 29–38, 2006.